AIA Brochure Q&A: ระบบ RAG ที่อ้างอิงแหล่งที่มา พร้อม agent

โปรเจกต์ปลายภาควิชา LLM · โค้ด: github.com/Calvinkub/aia-brochure-rag · chat model `gemma-4-E4B-it`, embeddings `bge-m3` ผ่าน proxy ของคลาส

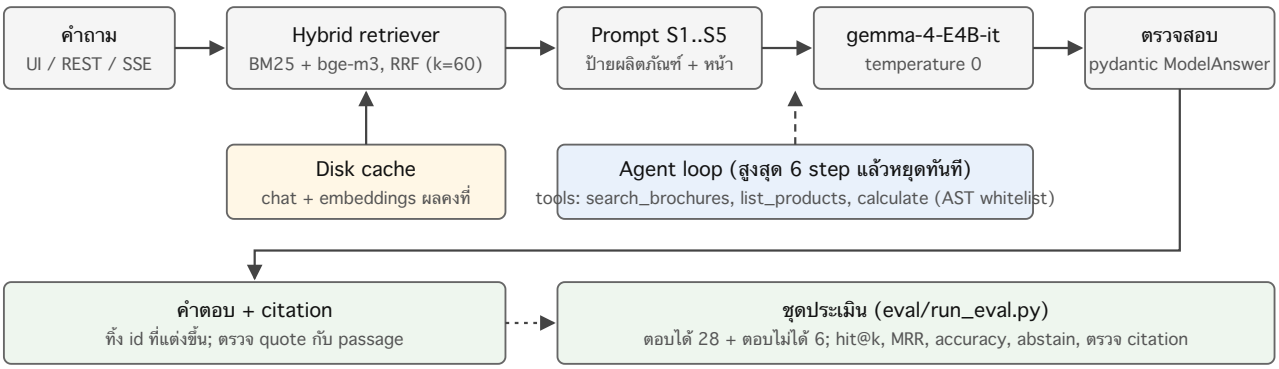
1. ปัญหาและกลุ่มผู้ใช้

โบรชัวร์ประกันมีข้อมูลที่ลูกค้าต้องใช้ เช่น ระยะเวลารอคอย (waiting period) อายุรับประกัน เปอร์เซ็นต์ผลประโยชน์ และค่าธรรมเนียม แต่ข้อมูลเหล่านี้อยู่ในตารางและหมายเหตุที่กระจายอยู่ในไฟล์ PDF หลายไฟล์ แชตบอตทั่วไปตอบจากความจำ ซึ่งสำหรับผลิตภัณฑ์เฉพาะของไทยมักเป็นการเดาที่มั่นใจเกินจริง โปรเจกต์นี้ตอบคำถามเกี่ยวกับผลิตภัณฑ์ AIA ประเทศไทย *จากข้อความในโบรชัวร์เท่านั้น* ระบุหน้าที่อ้างอิง และตอบว่า "โบรชัวร์ไม่ได้ระบุเรื่องนี้" เมื่อไม่มีหลักฐาน

ใครใช้: ผู้สนใจซื้อประกันหรือตัวแทนที่ต้องการคำตอบที่เร็วและตรวจสอบได้ ไม่ใช่คำแนะนำให้ซื้อ โปรเจกต์นี้เป็นงานในรายวิชา ไม่ใช่คำแนะนำด้านประกัน และโบรชัวร์มีอายุปี 2019–2022 ซึ่งอาจล้าสมัยแล้ว

ทำไมแอปอ้างอิงตอบไม่ได้: คลังเอกสารคือ PDF สาธารณะของ AIA ประเทศไทย 16 ไฟล์ ดาวน์โหลดด้วย `scripts/fetch_corpus.py` มี 15 ไฟล์ที่ดึงข้อความภาษาอังกฤษได้ (94 หน้า, 290 chunks) โมเดลแบบ closed-book ไม่มีความรู้ที่เชื่อถือได้เกี่ยวกับเอกสารเหล่านี้ ผลประเมินด้านล่างยืนยันเรื่องนี้ (แม่นยำเพียง 7% เมื่อบังคับให้เดา)

2. การออกแบบ



รูปที่ 1 เส้นทางของคำถาม (แถวบน), agent ที่เป็นอีกทางเลือกบน retriever ตัวเดียวกัน (สีฟ้า), และชุดประเมินที่ให้คะแนนผลลัพธ์ของเส้นทางนั้น

เทคนิคจากคอร์ส	ใช้อย่างไรในโปรเจกต์	เหตุผล
Prompting + structured output พร้อม schema validation	โมเดลต้องตอบเป็น JSON ตรงกับ `ModelAnswer` (answerable, answer, citations) โค้ดตัด code fence ออก ลอง repair หนึ่งครั้ง ถ้าไม่ผ่านระบบจะงดตอบ (abstain)	โค้ดส่วนถัดไปไม่เชื่อข้อความอิสระ
RAG พร้อม citation	แหล่งที่มาถูกเลขเป็น S1..S5 โมเดลอ้าง id ไม่ใช่เลขหน้า โค้ดแปลง id เป็นผลิตภัณฑ์และหน้า ทิ้ง id ที่โมเดลแต่งขึ้น และตั้ง `verified` ก็ต่อเมื่อ quote ปรากฏอยู่ใน passage ที่อ้างจริง (เทียบหลัง normalize ให้เหลือตัวอักษรและตัวเลข)	citation ที่ผู้ใช้ตรวจสอบไม่ได้เป็นเพียงของตกแต่ง
การประเมิน retrieval และคำตอบ	gold set ที่ติดป้ายด้วยมือ, hit@k และ MRR ระดับหน้า, accuracy ของคำตอบ, การ abstain, การตรวจ citation, baseline สามแบบ	เป็นหมวดที่บังคับ และเป็นเครื่องมือที่ใช้ตัดสินทุกการออกแบบด้านล่าง
Agent loop พร้อม tools	ใช้ function calling แบบ native มี allow-list, ตรวจ argument ด้วย pydantic, จำกัด 6 step, และถือผลลัพธ์ของ tool เป็นข้อมูลที่ไม่น่าเชื่อถือ `calculate` คำนวณเลขผ่าน AST whitelist (ไม่มี name, call หรือ attribute; จำกัด exponent)	ให้คำถามหลายขั้น (เทียบสองผลิตภัณฑ์, คำนวณผลประโยชน์) ใช้ search ร่วมกับการคำนวณได้อย่างปลอดภัย
Served interface	FastAPI: `POST /ask`, SSE `GET /ask/stream` และ `/agent/stream`, UI แบบเรียบง่ายที่ `/`	Streaming แสดงแหล่งที่ค้นพบก่อน และแสดง tool call ทันทีที่เกิดขึ้น

เลือก hybrid retrieval แทน dense อย่างเดียว เพราะคำถามเกี่ยวกับโบรชัวร์ผสมทั้งคำที่ต้องตรงเป๊ะ (ตัวเลข ชื่อผลิตภัณฑ์) และการถอดความ reciprocal-rank fusion ไม่ต้องปรับสเกลคะแนน API key และ base URL อ่านจาก environment เท่านั้น และไม่มี secret ใน commit

3. การประเมิน

ชุดทดสอบ (`eval/gold.jsonl`): คำถามที่ตอบได้ 28 ข้อ แต่ละข้อมีหลักฐานเป็น quote ตรงตัวอักษร ผลิตภัณฑ์และหน้าที่ถูกต้อง และ keyword ที่ต้องมี บวกคำถามที่ตอบไม่ได้ 6 ข้อ ซึ่งใกล้เคียงหัวข้อแต่ไม่มีในคลังเอกสาร (เช่น ระดับรางวัลของ Vitality) `eval/check_gold.py` ตรวจว่า quote ทุกอันอยู่ในข้อความของหน้านั้นจริง และตรวจว่าคำที่ใช้ในข้อที่ตอบไม่ได้ไม่ปรากฏในคลังเอกสาร คำถามร่างโดยใช้ AI ช่วยจากข้อความโบรชัวร์ การตรวจ quote ช่วยให้ป้ายกำกับน่าเชื่อถือ แต่ไม่ใช่ป้ายกำกับอิสระจากมนุษย์

เมตริก Retrieval: hit@k และ MRR โดย hit คือ chunk ใน top-k ที่มาจากผลิตภัณฑ์และหน้าที่ถูกต้อง ส่วนคำตอบ: *accuracy* (keyword ที่ต้องมีปรากฏครบเป็นคำเต็ม), *false abstain* (คำถามที่ตอบได้แต่ระบบปฏิเสธ), *abstain on unanswerable*, *cites gold page* และ *citation verified* (สัดส่วน citation ที่ quote อยู่ใน passage จริง) ทุกการรันใช้ temperature 0 และ cache บนดิสก์ ผลจึงทำซ้ำได้

Baseline (a) closed-book อนุญาตให้ปฏิเสธ (b) closed-book บังคับให้เดา (c) BM25 RAG ที่ใช้ chunk ชุดเดียวกัน แบบแรกได้ 0 เพราะโมเดลปฏิเสธทุกข้อเท่านั้น ดังนั้น (b) จึงเป็น baseline closed-book ที่ให้ข้อมูลจริง

4. ผลลัพธ์

4.1 คำตอบแบบ end-to-end (chunk 180 คำ / overlap 40, k = 5)

ระบบ	accuracy	false abstain	abstain ข้อที่ตอบไม่ได้	อ้างหน้าที่ถูก	citation verified
closed-book, ปฏิเสธได้ (baseline)	0.00	1.00	1.00	–	–
closed-book, บังคับเดา (baseline)	0.07	0.29	0.50	–	–
BM25 RAG, ไม่มี floor (baseline)	0.93	0.04	1.00	0.93	0.95
hybrid RAG, ไม่มี floor (ที่ใช้จริง)	**0.93**	**0.00**	**1.00**	**0.93**	**1.00**
hybrid RAG, `min_score` = 0.65	0.89	0.04	1.00	0.89	1.00

ตารางที่ 1 n = 28 ข้อที่ตอบได้, 6 ข้อที่ตอบไม่ได้ ต่างกัน 1 ข้อ = accuracy ต่างกัน 0.036

- **Retrieval คือสิ่งที่ทำให้ระบบใช้ได้** closed-book แบบบังคับเดาตอบถูก 2 จาก 28 ข้อ และยังตอบ 3 จาก 6 ข้อที่ตอบไม่ได้ทั้งที่ไม่ควรตอบ เมื่อใช้ retrieval: ถูก 26 จาก 28 และไม่ตอบข้อที่ตอบไม่ได้เลย
- **การปรับปรุงที่วัดได้เมื่อเทียบกับค่าเริ่มต้นแบบง่าย** (BM25, chunk เดียวกัน): hybrid เพิ่ม MRR จาก 0.832 เป็น 0.882, hit@1 จาก 0.79 เป็น 0.82, สัดส่วน citation-verified จาก 0.95 เป็น 1.00 และกำจัด false abstain ที่มีอยู่หนึ่งข้อ แต่ n = 28 หมายถึงต่างกันหนึ่งหรือสองข้อ เป็นเพียงทิศทาง ไม่ใช่ผลที่มีนัยสำคัญทางสถิติ
- `min_score` **เป็นผลลบ** เกณฑ์ 0.65 ดูเหมือนไม่มีต้นทุนเมื่อทดสอบระดับคำถาม (เก็บข้อที่ตอบได้ครบ 28 ข้อ และกันข้อที่ตอบไม่ได้ได้ 4 จาก 6) แต่เมื่อใช้เป็น floor ระดับ chunk มันตัด chunk ที่ถูกต้องทิ้ง (cosine 0.62) และทำให้เสียคำตอบไปหนึ่งข้อ (0.93 เหลือ 0.89) โมเดลปฏิเสธข้อที่ตอบไม่ได้ครบ 6 ข้ออยู่แล้ว จึงตั้งค่าเริ่มต้นเป็น 0

4.2 การทดสอบ retrieval (n = 28, k = 5)

chunk คำ/overlap	โหมด	hit@1	hit@3	hit@5	MRR
80/20	bm25 / dense / hybrid	0.75 / 0.75 / 0.79	0.93 / 0.93 / 0.93	0.93 / 0.96 / 0.93	0.839 / 0.842 / 0.857
180/40 (ที่เลือก)	**bm25 / dense / hybrid**	**0.79 / 0.79 / 0.82**	**0.86 / 0.93 / 0.93**	**0.93 / 0.96 / 0.96**	**0.832 / 0.852 / 0.882**
350/60	bm25 / dense / hybrid	0.75 / 0.68 / 0.75	0.96 / 0.86 / 0.96	0.96 / 0.96 / 0.96	0.845 / 0.787 / 0.857

ตารางที่ 2 ขนาด chunk และโหมด retrieval chunk 350 คำทำให้ dense retrieval แย่ลงมากที่สุด

4.3 การทดลองเรื่อง chunking

baseline E0 ตัดหน้าต่างคงที่ 180 คำ: 74% ของ chunk จบกลางประโยค และประมาณ 15% ของข้อความเป็นหมายเหตุที่ซ้ำทุกหน้า มีสี่เทคนิคที่มาจากการสืบค้นเอกสารด้วย NotebookLM (แหล่งจากเว็บ ตัวเลขไม่ได้ตรวจสอบอิสระ) และวัดแต่ละเทคนิคบน gold set ชุดเดียวกัน ไม่ได้ทดลอง late chunking เพราะต้องใช้ embedding model ที่ proxy ไม่มี และไม่ได้ทดลอง semantic chunking เพราะมีรายงานว่าทำให้ข้อความสั้นแตกเป็นชิ้นเล็กเกินไป

	pipeline	chunks	hybrid MRR	dense MRR	acc. คำตอบ	citation verified
E0	**baseline: หน้าต่าง 180 คำ**	**290**	**0.882**	**0.852**	**0.93**	**1.00**
E1	+ ลบ boilerplate ที่ซ้ำ, จัด chunk ตามประโยค	249	0.893	0.878	0.89	0.97
E2	ตาราง markdown จาก PyMuPDF4LLM, ใส่ header row ซ้ำในทุก chunk	262	0.875	0.788	0.96	0.92
E3	E2 + ประโยคบริบทที่ LLM เขียนให้ทุก chunk	262	0.873	0.848	0.96	0.88
E4	parent-child: child ~60 คำ ส่งทั้งหน้ากลับ	650	0.889	0.923	0.93	0.95

ตารางที่ 3 accuracy ของคำตอบและ citation verified เป็นค่าของ hybrid retrieval

ไม่มี variant ใดชนะ baseline อย่างชัดเจน accuracy เปลี่ยนไป ±1 ข้อ (25–27 จาก 28) และ MRR เปลี่ยน 0.01–0.04 ทั้งหมดอยู่ในระดับ noise ของ n = 28 E1 ลดสัดส่วน chunk ที่จบกลางประโยคจาก 74% เหลือ 13% แต่ accuracy ไม่เพิ่ม E2 และ E3 แก้คำถามได้หนึ่งข้อ (A24) แต่ทำให้สัดส่วน citation ที่ตรวจสอบได้ลดจาก 1.00 เหลือ 0.88–0.92 โดยยังไม่ได้ตรวจสอบสาเหตุ E4 แบบ dense อย่างเดียวเป็น retriever ที่ดีที่สุด (hit@3 = hit@5 = 1.00, MRR 0.923) แต่ไม่ได้ประเมินคำตอบ เพื่อไม่ให้ปรับจูนบนคำถามชุดเดิมเพิ่ม จึงเป็นสมมติฐานสำหรับคำถามชุดใหม่ ไม่ใช่ผลลัพธ์ E0 ยังเป็นค่าเริ่มต้น ส่วน variant อื่นเปิดใช้เองได้

5. กรณีที่ล้มเหลว

id	คำถาม	เกิดอะไรขึ้น	สาเหตุ
A07	AIA CI Care คุ้มครองโรคร้ายแรงระยะรุนแรงกี่โรค?	ตอบ 44 แต่ป้ายกำกับ (gold) คือ 40	โบรชัวร์ขัดแย้งกันเอง: หน้า 1 เขียน "Cover 44 severe stage critical illnesses" ส่วนหัวตารางหน้า 2 เขียน "Severe Stage (40 Diseases / Treatment)" ป้ายกำกับ gold ยึดตาราง โมเดลยึดหน้า 1 ซึ่งเป็นการอ่านที่มีหลักฐานรองรับ นี่คือความขัดแย้งของแหล่งข้อมูล ไม่ใช่ hallucination พฤติกรรมที่ควรเป็นคือแจ้งความขัดแย้ง แต่ระบบยังทำไม่ได้
A24	Infinite Wealth Prestige เลือกระยะเวลาชำระเบี้ยได้กี่แบบ?	ตอบด้วย *ความถี่* ในการชำระเบี้ย top-up (รายเดือน รายไตรมาส)	chunk ที่ถูกต้อง (หน้า 3) อยู่อันดับ 5 โมเดลตอบจาก passage อันดับสูงกว่าที่ใช้คำว่า "payment period" คนละความหมาย
A17 (เฉพาะเมื่อมี floor)	ลดหย่อนภาษีสูงสุดของ Smart Select เท่าไร?	false abstain	floor `min_score` = 0.65 ตัด chunk ที่เป็นหลักฐานทิ้ง

> **การแก้ไขที่บันทึกไว้** ตอนแรกผมวินิจฉัย A07 ว่าโมเดลแต่งเลข "44" เพราะตารางที่ถูก flatten เสียโครงสร้าง เมื่ออ่านหน้า 1 อีกครั้งพบว่าตัวเลขนั้นอยู่ในโบรชัวร์จริง การวินิจฉัยนั้น และ README ที่พูดซ้ำ ผิด และได้แก้ไขแล้ว บทเรียนต่อการประเมิน: ป้ายกำกับอาจเป็นฝ่ายที่ถูกโต้แย้งได้ ทุกกรณีล้มเหลวจึงต้องเปิดดูแหล่งข้อมูลก่อนโทษโมเดล

6. ข้อจำกัดและงานต่อไป

- **eval เล็ก สร้างเอง และปรับจูนบนชุดเดียวกัน** ขนาด chunk, โหมด retrieval และ `min_score` เลือกโดยดูคำถามชุดเดียวกัน 34 ข้อ ไม่มี held-out set ตัวเลขที่รายงานจึงมีแนวโน้มสูงกว่าความจริง และความต่างหนึ่งข้อคือ noise

- **การให้คะแนนด้วย keyword เป็นเพียง proxy** อาจให้คะแนนคำตอบที่มีตัวเลขถูกแต่ผิดบริบท และอาจพลาดคำตอบที่ถูกแต่ถอดความ มี gold keyword หนึ่งตัวที่เป็นเพียงรากคำ ทำให้คำตอบที่ถูกถูกตัดสินว่าผิด จึงเปลี่ยนเป็นคำเต็ม ไม่ได้ใช้ LLM เป็นผู้ตัดสิน
- **ระบบไม่แจ้งเมื่อแหล่งข้อมูลขัดแย้งกัน** (A07) และตารางใน PDF ถูก flatten เมื่อใช้ parser ค่าเริ่มต้น parser ตาราง (E2) ไม่ช่วยให้ดีขึ้นอย่างวัดได้ในชุดนี้ ผลของการ flatten จึงยังไม่ได้ทดสอบ ไม่ใช่ถูกหักล้าง
- **เฉพาะโบรชัวร์ภาษาอังกฤษ** มีไฟล์สามไฟล์ที่ติดป้าย English แต่จริงๆ เป็นภาษาไทยและดึงข้อความออกมาเป็นขยะ จึงถูกกรองออก ผลิตภัณฑ์บางตัว (ประกันชั่วระยะเวลา, endowment, pay-life) จึงมีข้อมูลน้อยหรือไม่มี
- **ยังไม่ได้ประเมิน agent เชิงปริมาณ** ทดสอบด้วยมือ (เทียบหลายผลิตภัณฑ์, ทดสอบการปฏิเสธ argument) ในการรันด้วยมือครั้งหนึ่ง agent คูณเลขเองแทนที่จะเรียก `calculate`
- **โมเดลตระกูลเดียวทำทุกอย่าง** ไม่มีผู้ตัดสินอิสระ และพึ่ง proxy ของคลาส repo สร้างขึ้นในช่วงทำงานครั้งเดียว ประวัติ commit จึงเป็นลำดับ commit สั้นๆ ที่แบ่งตามงาน

งานต่อไป: ตรวจจับและรายงานตัวเลขที่ขัดแย้งกันระหว่าง passage ที่ดึงมา; ทดสอบ parent-child แบบ dense อย่างเดียวบนคำถามชุดใหม่; หาสาเหตุที่ variant แบบตารางทำให้ citation verification ลดลง; เขียน gold set ที่ใหญ่ขึ้นและแยกเป็น held-out ที่ระบบไม่เคยถูกปรับจูนกับมัน; สร้าง gold set ให้ agent; รองรับภาษาไทย